

Tema 04 III: Aprendizaje

◆ **Aprendizaje:** Bibliografía y recursos

Bibliografía de referencia

Pajares y Cruz (2005) **Inteligencia Artificial e Ingeniería del Conocimiento**, capítulos 13 y 14;

Pajares y Cruz (2007) **Ejercicios Resueltos de Visión por computador**

Pajares y Cruz (2010) **Aprendizaje Automático**

Software de apoyo:

Neural Network Toolbox y en general de MATLAB: herramienta para la implementación de redes neuronales con una amplia capacidad funcional.

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** modelos para el tratamiento de datos

Estimadores estadísticos

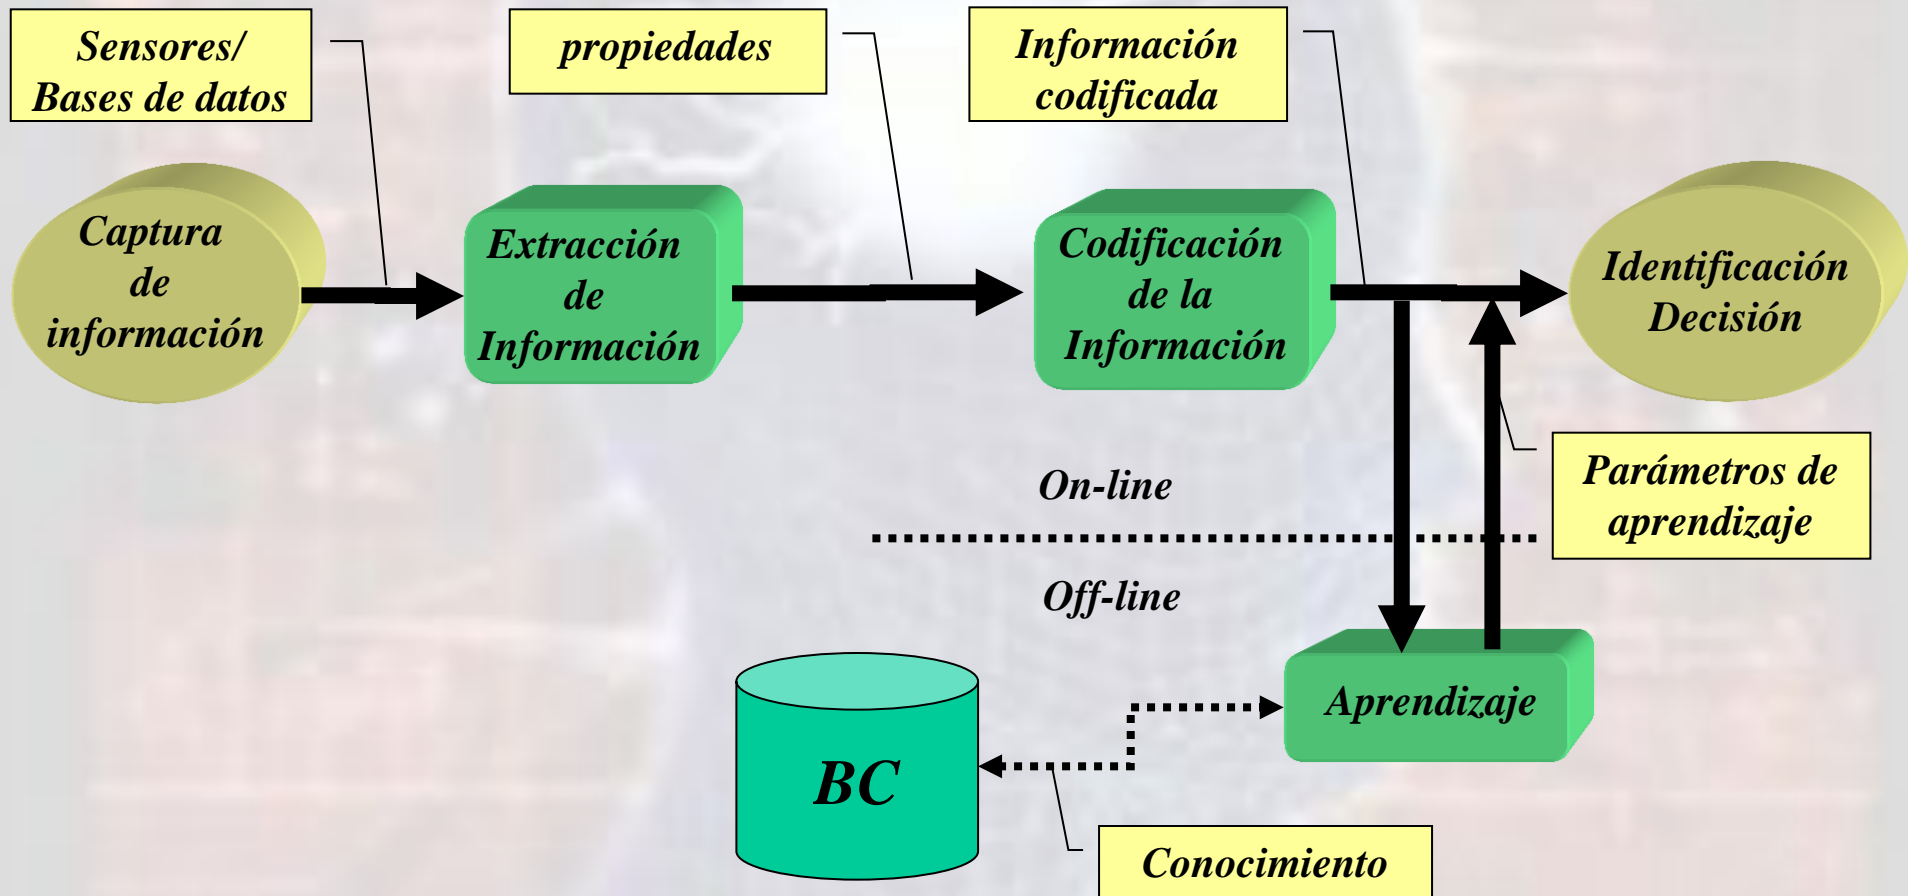
- *Agrupamiento borroso*
- *Clasificador paramétrico de Bayes*

Redes neuronales

- *Algoritmo generalizado de Lloyd*
- *Mapas autoorganizativos (SOM)*
- *Cuantización vectorial*
- *Perceptrón y red retropropagación*

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** esquema general



◆ **Aprendizaje:** captura de muestras

Clases: cielo, vegetación y agua



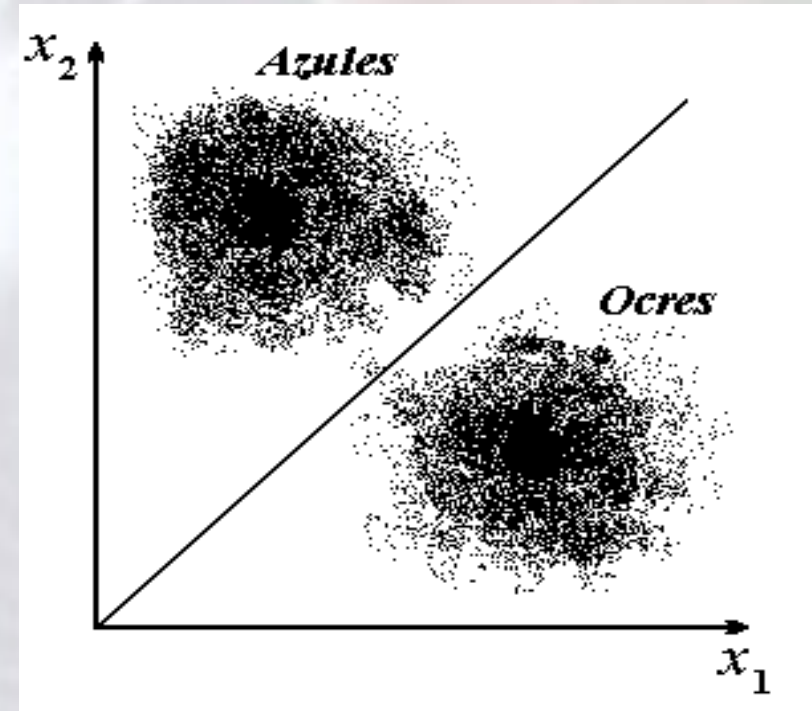
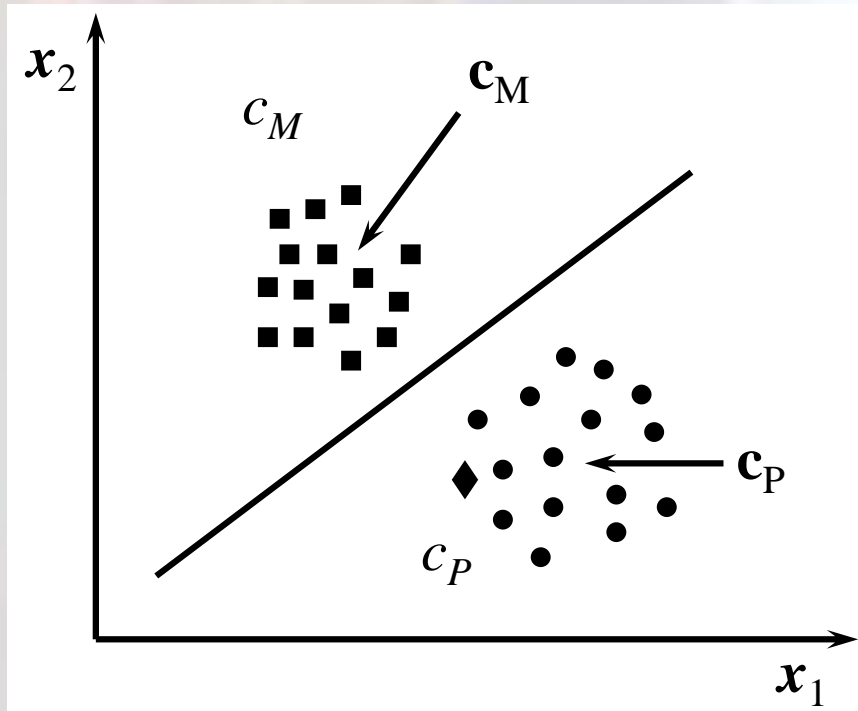
Entrenamiento y aprendizaje

Clasificación



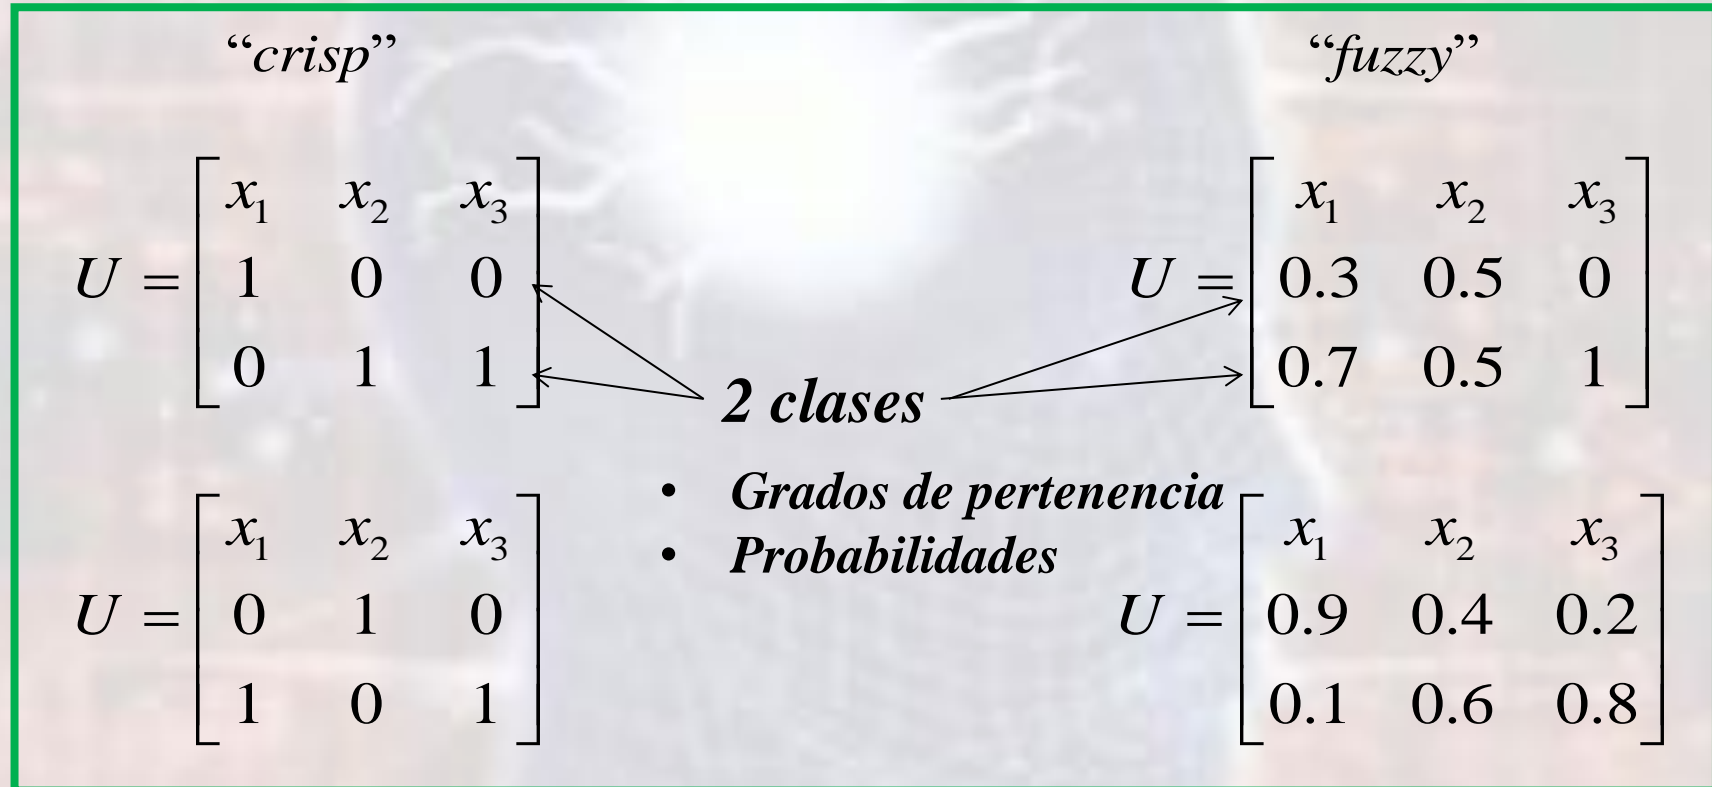
Tema 04 III : Aprendizaje

◆ Aprendizaje: Clases



Tema 04 III : Aprendizaje

◆ Aprendizaje: agrupamiento borroso



Tema 04 III : Aprendizaje

◆ Aprendizaje: agrupamiento K-medias

Algoritmo K-medias

- 1.- Extraer el número de muestras ***n*** a utilizar y el número de clases ***c***.
- 2.- Inicializar los centros de las clases ***v_i*** y las probabilidades , $i = 1 \dots c; j = 1 \dots n$
- 3.- Normalizar las probabilidades por medio de la ecuación ; $i = 1 \dots c$
- 4.- Obtener ***v_i*** de acuerdo con la ecuación (1)
- 5.- Recalcular por medio de la ecuación (2)
- 6.- Repetir los pasos 3 a 5 hasta que ***v_i*** no cambien o el cambio sea pequeño .

Ecuaciones:

$$v_i = \frac{\sum_{j=1}^n [P(c_i / \mathbf{x}_j)]^b \mathbf{x}_j}{\sum_{j=1}^n [P(c_i / \mathbf{x}_j)]^b} \quad i = 1, \dots, c \quad (1)$$

$$P(v_i / \mathbf{x}_j) = \frac{1/d_{ij}^{1/(b-1)}}{\sum_{r=1}^c 1/d_{rj}^{1/(b-1)}} \quad \text{y} \quad d_{ij} = \|\mathbf{x}_j - v_i\|^2 \quad i = 1, \dots, c; j = 1, \dots, n \quad (2)$$

$$\Delta = \left\| v_i^{(t+1)} - v_i^{(t)} \right\| < \varepsilon \quad \text{criterio finalización}$$

Tema 04 III : Aprendizaje

◆ Aprendizaje: agrupamiento K-medias

Ejercicio_10_01.m

Entrenamiento

2 clases x_1 1 1 1 2 2 6 6 7 7 7
 x_2 1 3 5 2 3 3 4 1 3 5 $b = 2$ $\varepsilon = 0.02$

Clasificación $x_k = (3,4)$

**Revisar los
valores de
este ejemplo**

Centros iniciales: $v_1 = 6.70, 3.43$; $v_2 = 2.39, 2.94$

$U^0 =$ 0.022 0.003 0.030 0.002 0.000 0.997 0.997 0.946 1.000 0.990
 0.978 0.997 0.970 0.998 1.000 0.003 0.003 0.054 0.000 0.010

Iteración 1: $v_1 = 6.57, 3.24$; $v_2 = 1.41, 2.79$

$$\Delta = \|v_i^{(t+1)} - v_i^{(t)}\| = 0.0267 > \varepsilon$$

$U^1 =$ 0.009 0.000 0.021 0.002 0.000 1.000 0.998 0.978 1.000 0.992
 0.991 1.000 0.979 0.998 1.000 0.000 0.002 0.022 1.000 0.008

Tema 04 III : Aprendizaje


◆ Aprendizaje: agrupamiento K-medias

Entrenamiento

Iteración 2:

$$v_1 = 6.60, 3.21 ; \quad v_2 = 1.40, 2.79$$

$$\Delta = \|v_i^{(t+1)} - v_i^{(t)}\| = 0.000067 < \varepsilon \longrightarrow \textit{Fin}$$



Tema 04 III : Aprendizaje

◆ Aprendizaje: agrupamiento K-medias

Clasificación

pertenencia de $\mathbf{x}_k = (2,3)$

$$\|\mathbf{x}_k - \mathbf{v}_1\|_G^2 = 2 - 6.60^2 + 3 - 3.21^2 = 20.96$$

$$\|\mathbf{x}_k - \mathbf{v}_2\|_G^2 = 2 - 1.40^2 + 3 - 2.79^2 = 0.39$$

$$P(\mathbf{v}_1 / \mathbf{x}_k) = 0.1575 \quad P(\mathbf{v}_2 / \mathbf{x}_k) = 0.8425$$

$\mathbf{x}_k = (2,3)$ pertenece a la clase 2 representada por \mathbf{v}_2

$$\mathbf{v}_2 = 1.40, 2.79 \quad \mathbf{v}_1 = 6.60, 3.21$$

x_1	1	1	1	2	2	6	6	7	7	7
x_2	1	3	5	2	3	3	4	1	3	5


clase 2

clase 1


Tema 04 III : Aprendizaje

◆ **Aprendizaje:** estimación paramétrica Bayes


Cada clase sigue una distribución cuya densidad de probabilidad es:



$$p(\mathbf{x}_i/C_1, \mathbf{m}_1)$$



$$p(\mathbf{x}_i/C_2, \mathbf{m}_2)$$



$$p(\mathbf{x}_i/C_c, \mathbf{m}_c)$$

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** estimación paramétrica Bayes

Caso normal multivariable

Sea $X = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ un conjunto de n muestras

Función a estimar por máxima verosimilitud

$$f(\mathbf{x}_i, \mathbf{w}) = p(\mathbf{x}_i / \mathbf{m}, C) = \frac{1}{(2\pi)^{d/2} |C|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_i - \mathbf{m})^t C^{-1} (\mathbf{x}_i - \mathbf{m}) \right\}$$

donde $\mathbf{w} = \{w_1, w_2\}$ es el vector de parámetros a “aprender” (estimar)

Resultado:

$$\hat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \quad C = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \hat{\mathbf{m}})(\mathbf{x}_i - \hat{\mathbf{m}})^t$$


$\mathbf{w} = \{\mathbf{m}, C\} \Rightarrow$ vector de parámetros aprendido

Tema 04 III : Aprendizaje

◆ Aprendizaje: estimación paramétrica

Ejemplo 1

Entrenamiento



$$\mathbf{m}_1 = \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{m}_2 = \frac{1}{4} \begin{bmatrix} 1 \\ 3 \\ 3 \end{bmatrix}$$

$$\mathbf{C}_1 = \mathbf{C}_2 = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}$$

Tema 04 III : Aprendizaje

◆ Aprendizaje: estimación paramétrica

Ejemplo 2

Sea $X = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ el conjunto de muestras dado en la tabla siguiente, correspondiente a muestras de una tonalidad verde-azulada

muestras	R	G	B
\mathbf{x}_1	50	250	200
\mathbf{x}_2	10	254	180
\mathbf{x}_3	20	240	210
\mathbf{x}_4	40	248	190
\mathbf{x}_5	56	254	202
\mathbf{m}	35.2	249.2	196.4

$$\mathbf{m} = (\mathbf{x}_1 + \mathbf{x}_2 + \mathbf{x}_3 + \mathbf{x}_4 + \mathbf{x}_5)/5 = (35.2, 249.2, 196.4)$$

$$C = ((\mathbf{x}_1 - \mathbf{m})' (\mathbf{x}_1 - \mathbf{m}) + (\mathbf{x}_2 - \mathbf{m})' (\mathbf{x}_2 - \mathbf{m}) + (\mathbf{x}_3 - \mathbf{m})' (\mathbf{x}_3 - \mathbf{m}) + (\mathbf{x}_4 - \mathbf{m})' (\mathbf{x}_4 - \mathbf{m}) + (\mathbf{x}_5 - \mathbf{m})' (\mathbf{x}_5 - \mathbf{m}))/5$$

$$= \begin{pmatrix} 308.16 & 24.96 & 69.12 \\ 24.96 & 26.56 & -33.28 \\ 69.12 & -33.28 & 107.84 \end{pmatrix}$$

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** estimación estadística, ejercicio propuesto

Ejemplo: estimar las funciones de densidad paramétrica para las dos clases dadas

Vectores patrón:	
Clases	$x_1 = (1,2)^t$
	$x_2 = (2,2)^t$
	$c_1: x_3 = (3,1)^t$
	$x_4 = (2,3)^t$
	$x_5 = (3,2)^t$
	$c_2: x_6 = (8,10)^t$
	$x_7 = (9,8)^t$
	$x_8 = (9,9)^t$
	$x_9 = (8,9)^t$
	$x_{10} = (7,9)^t$

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** Agrupamiento K-Medias y Bayes

Ejemplos de aplicación:

K-Means imágenes lente ojo de pez (Herrera, Pajares, Guijarro)

K-Means en agricultura (Romeo, Pajares, Montalvo, Guerrero, Guijarro, de la Cruz)


K-Means y Bayes imágenes aéreas (Guijarro, Pajares, Herrera)

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** cuantización vectorial

Cuantización vectorial:

Un cuantificador vectorial Q es una proyección del espacio euclídeo d -dimensional \mathbb{R}^d en un subconjunto finito C de \mathbb{R}^d



Aprendizaje

Se aprenden los centros

$$C = \{\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_m\}$$

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** cuantización vectorial

Algoritmo de Lloyd (algoritmo competitivo)

- 1) **Inicio:** dados los puntos de datos $\mathbf{x}(k)$, $k = 1, 2, \dots$,
y centros de salida iniciales $\mathbf{c}_j(0)$, $j = 1, \dots, m$.
- 2) Determinar el centro $\mathbf{c}_j(k)$ más próximo al punto $\mathbf{x}(k)$ (competición)

$$j = \arg \min_j \|\mathbf{x}(k) - \mathbf{c}_j(k)\|$$

- 3) Actualizar el centro de salida utilizando las ecuaciones,

$$\mathbf{c}_j(k+1) = \mathbf{c}_j(k) + \gamma(k) [\mathbf{x}(k) - \mathbf{c}_j(k)]$$

$$k = k + 1$$

$\gamma(k)$ razón de aprendizaje

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** cuantización vectorial

Entrenamiento

2 clases

x_1	1	1	1	2	2	6	6	7	7	7
x_2	1	3	5	2	3	3	4	1	3	5

2 centros iniciales $c_1 = (1,4)^t$ y $c_2 = (7,2)^t$

razón de aprendizaje $\gamma(k_j) = 0.1$

Clasificación

$$A = (6,2)^t$$

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_07.m

Iteración 1:

$\mathbf{x}^1=(1,1)^t \rightarrow d_1 = 3.00$ y $d_2 = 6.08$, por tanto se actualiza c_1


$$c_1 = \begin{pmatrix} 1 \\ 4 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 4 \end{pmatrix} \right] = \begin{pmatrix} 1.0 \\ 3.7 \end{pmatrix}$$

$\mathbf{x}^2=(1,3)^t \rightarrow d_1 = 0.70$ y $d_2 = 6.08$, por tanto se actualiza c_1

$$c_1 = \begin{pmatrix} 1.0 \\ 3.7 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 1 \\ 3 \end{pmatrix} - \begin{pmatrix} 1.0 \\ 3.7 \end{pmatrix} \right] = \begin{pmatrix} 1.0 \\ 3.6 \end{pmatrix}$$

$\mathbf{x}^3=(1,5)^t \rightarrow d_1 = 1.37$ y $d_2 = 6.71$, por tanto se actualiza c_1

$$c_1 = \begin{pmatrix} 1.0 \\ 3.6 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 1 \\ 5 \end{pmatrix} - \begin{pmatrix} 1.0 \\ 3.6 \end{pmatrix} \right] = \begin{pmatrix} 1.0 \\ 3.8 \end{pmatrix}$$



Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_07.m

$\mathbf{x}^4=(2,2)^t \rightarrow d_1 = 2.03$ y $d_2 = 5.0$, por tanto se actualiza c_1

$$c_1 = \begin{pmatrix} 1.0 \\ 3.8 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 2 \\ 2 \end{pmatrix} - \begin{pmatrix} 1.0 \\ 3.8 \end{pmatrix} \right] = \begin{pmatrix} 1.1 \\ 3.6 \end{pmatrix}$$

$\mathbf{x}^5=(2,3)^t \rightarrow d_1 = 1.1$ y $d_2 = 5.1$, por tanto se actualiza c_1

$$c_1 = \begin{pmatrix} 1.1 \\ 3.6 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 2 \\ 3 \end{pmatrix} - \begin{pmatrix} 1.1 \\ 3.6 \end{pmatrix} \right] = \begin{pmatrix} 1.2 \\ 3.5 \end{pmatrix}$$

$\mathbf{x}^6=(6,3)^t \rightarrow d_1 = 4.8$ y $d_2 = 1.4$, por tanto se actualiza c_2

$$c_2 = \begin{pmatrix} 7 \\ 2 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 6 \\ 3 \end{pmatrix} - \begin{pmatrix} 7 \\ 2 \end{pmatrix} \right] = \begin{pmatrix} 6.9 \\ 2.1 \end{pmatrix}$$

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_07.m

$\mathbf{x}^7=(6,4)^t \rightarrow d_1 = 4.8$ y $d_2 = 2.1$, por tanto se actualiza c_2

$$c_2 = \begin{pmatrix} 6.9 \\ 2.1 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 6 \\ 4 \end{pmatrix} - \begin{pmatrix} 6.9 \\ 2.1 \end{pmatrix} \right] = \begin{pmatrix} 6.8 \\ 2.3 \end{pmatrix}$$

$\mathbf{x}^8=(7,1)^t \rightarrow d_1 = 6.3$ y $d_2 = 1.3$, por tanto se actualiza c_2

$$c_2 = \begin{pmatrix} 6.8 \\ 2.3 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 7 \\ 1 \end{pmatrix} - \begin{pmatrix} 6.8 \\ 2.3 \end{pmatrix} \right] = \begin{pmatrix} 6.8 \\ 2.2 \end{pmatrix}$$

$\mathbf{x}^9=(7,3)^t \rightarrow d_1 = 5.8$ y $d_2 = 0.9$, por tanto se actualiza c_2

$$c_2 = \begin{pmatrix} 6.8 \\ 2.2 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 7 \\ 3 \end{pmatrix} - \begin{pmatrix} 6.8 \\ 2.2 \end{pmatrix} \right] = \begin{pmatrix} 6.8 \\ 2.2 \end{pmatrix}$$

$\mathbf{x}^{10}=(7,5)^t \rightarrow d_1 = 6.0$ y $d_2 = 2.8$, por tanto se actualiza c_2

$$c_2 = \begin{pmatrix} 6.8 \\ 2.2 \end{pmatrix} + 0.1 \left[\begin{pmatrix} 7 \\ 5 \end{pmatrix} - \begin{pmatrix} 6.8 \\ 2.2 \end{pmatrix} \right] = \begin{pmatrix} 6.9 \\ 2.5 \end{pmatrix}$$

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_07.m

Iteración 2:

Realizando el mismo proceso que en la iteración anterior, llegamos al resultado final: $c_1 = (1.3, 3.3)^t$ y $c_2 = (6.8, 2.8)^t$. Observando que se han producido cambios en esta segunda iteración con respecto a los valores obtenidos en la iteración 1.

La clasificación de $A = (6, 2)^t$ se realiza computando la distancia del mismo a cada uno de los centros de las clases y eligiendo la clase de pertenencia la de menor distancia:

$$d(A, c_1) = \|A - c_1\| = 4.862 \quad \text{y} \quad d(A, c_2) = \|A - c_2\| = 1.137$$

Clasificación

Por tanto, A se clasifica como perteneciente a la clase c_2

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** cuantización vectorial (SOM)

Self-Organizing Map (algoritmo competitivo)

- 1) **Inicio:** dados los puntos de datos $\mathbf{x}(k)$, $k = 1, 2, \dots$,
y centros de salida iniciales $\mathbf{c}_j(0)$, $j = 1, \dots, m$.
- 2) Actualizar los centros
$$\mathbf{c}_j(k+1) = \begin{cases} \mathbf{c}_j(k) + \gamma(k) [\mathbf{x}(k) - \mathbf{c}_j(k)] & \text{si } \mathbf{c}_j \in K_{\alpha(k)} \\ \mathbf{c}_j(k) & \text{en cualquier otro caso} \end{cases}$$
$$k = k + 1$$

Consideraciones

Razón de aprendizaje: $\gamma(k)$

Región de vecindad: $K_{\alpha(k)} = (\mathbf{z}, \mathbf{z}') = \exp\left(-\frac{\|\mathbf{z} - \mathbf{z}'\|^2}{2\alpha^2(k)}\right)$ con $\alpha(k) = \alpha_{inicial} \left(\frac{\alpha_{final}}{\alpha_{inicial}}\right)^{k/k_{max}}$

donde k es el número de iteración y k_{max} es el número máximo de iteraciones. El ancho inicial de la vecindad $\alpha_{inicial}$ se elige de modo que dicha vecindad cubra todas las unidades y el ancho final de la vecindad α_{final} controla el grado de variación del núcleo entre iteraciones consecutivas.

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial (SOM)

Ejercicio_09_09.m

Entrenamiento

2 clases

x_1	1	1	2	6	6	7
x_2	3	5	2	3	4	3

Sabiendo que existen dos únicas clases cuyos centros inicialmente son $c_1 = (1,4)^t$ y $c_2 = (7,2)^t$, ajustar dichos centros a los datos siguiendo el algoritmo SOM con una única iteración. Tomar como referencia los siguientes valores de los parámetros $\alpha_{inicial} = 1.0$, $\alpha_{final} = 0.8$, $k_{max} = 5.0$. Dadas dos muestras \mathbf{z} y \mathbf{z}' se dice que pertenecen a la región definida por $\alpha(k)$ si $K_{\alpha(k)}(\mathbf{z}, \mathbf{z}') > T$, siendo $T = 0.2$ en este ejemplo. La razón de aprendizaje viene dada por la siguiente expresión $\gamma(k) = 1/(10+k)$.

Clasificación

$$A = (6,2)^t$$

◆ Aprendizaje: cuantización vectorial (SOM)

Iteración 1 ($k = 1$):

$$\gamma(1) = 1/(10+1) = 0.0909; \quad \alpha(1) = 0.9564$$

$$\mathbf{x}^1 = (1, 3)^t$$

$K_{\alpha(1)}(\mathbf{x}^1, \mathbf{c}_1) = 0.58 > T$ y $K_{\alpha(1)}(\mathbf{x}^1, \mathbf{c}_2) = 1.6 \times 10^{-9} < T$ luego sólo se actualiza \mathbf{c}_1 . En el supuesto de que los dos valores fueran menores que T se actualizarían los dos centros

$$\mathbf{c}_1 = \begin{pmatrix} 1 \\ 4 \end{pmatrix} + 0.0909 * 0.58 \left[\begin{pmatrix} 1 \\ 3 \end{pmatrix} - \begin{pmatrix} 1 \\ 4 \end{pmatrix} \right] = \begin{pmatrix} 1.0000 \\ 3.9996 \end{pmatrix}$$

procediendo de este modo para el resto de patrones \mathbf{x}^2 a \mathbf{x}^6 ; se obtienen al final de esta primera iteración los siguientes centros:

$$\mathbf{c}_1 = (1.0000, 3.9996)^t \quad \text{y} \quad \mathbf{c}_2 = (6.9712, 2.0832)^t$$

El proceso se repite para el resto de iteraciones, llegando a obtener los siguientes valores para los centros al cabo de las 5 iteraciones previstas,

$$\mathbf{c}_1 = (1.0000, 3.9972)^t \quad \text{y} \quad \mathbf{c}_2 = (6.8902, 2.3225)^t$$

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** cuantización vectorial (SOM)

Ejercicio_09_09.m

Clasificación

La clasificación de $A = (6, 2)^t$ se realiza computando la distancia del mismo a cada uno de los centros de las clases y eligiendo la clase de pertenencia con la menor distancia:

$$d(A, c_1) = \|A - c_1\| = 5.3841 \text{ y } d(A, c_2) = \|A - c_2\| = 0.9468$$

Por tanto, A se clasifica como perteneciente a la clase c_2 .

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_10.m

Entrenamiento

	patrones							
	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
<i>2 clases</i> R	200	90	210	35	215	92	87	41
G	160	130	170	23	172	138	128	22
B	120	60	130	44	133	54	66	37

$$T = 20$$

Clasificación

$$A = (93, 120, 70)^t$$

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_10.m

1) Inicialmente se crea una única clase c_1 formada por el primer patrón a procesar

$$x_1 = \{200, 160, 120\} \text{ cuyo centro es } v_1 = \{200, 160, 120\}, c_1 = \{x_1\}$$

2) segundo patrón $x_2 = \{90, 130, 60\}$ calculamos la distancia al único centro disponible $d(x_2, v_1) = \|x_2 - v_1\| = 128.84 > T$, por tanto, creamos una nueva clase con el patrón dado $c_2 = \{x_2\}$, cuyo centro resulta ser este mismo patrón $v_2 = \{90, 130, 60\}$.

3) tercer patrón $x_3 = \{210, 170, 130\}$ calculando las distancias a los dos centros de clase existentes $d(x_3, v_1) = \|x_3 - v_1\| = 17.32$ $d(x_3, v_2) = \|x_3 - v_2\| = 144.57$, siendo el mínimo $d(x_3, v_1) < T$, por tanto este nuevo patrón se añade a la clase c_1 , quedando ésta como sigue $c_1 = \{x_1, x_3\}$. Se actualiza el centro de la clase c_1 , calculando el valor medio entre x_1 y x_3 , resultando $v_1 = \{205, 165, 125\}$.

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_10.m

4) cuarto patrón $x_4 = \{35, 23, 44\}$ calculando las distancias a los dos centros de clase existentes $d(x_4, v_1) = \|x_4 - v_1\| = 235.85$ $d(x_4, v_2) = \|x_4 - v_2\| = 121.37$, siendo el mínimo $d(x_4, v_2) > T$ por tanto, es necesario crear una nueva clase $c_3 = \{x_4\}$ cuyo centro es este mismo patrón $v_3 = \{35, 23, 44\}$.

5) quinto patrón $x_5 = \{215, 172, 133\}$ calculando las distancias a los tres centros de clase existentes $d(x_5, v_1) = 14.59$, $d(x_5, v_2) = 150.72$ y $d(x_5, v_3) = 250.04$ · siendo el mínimo $d(x_5, v_1) < T$ por tanto, el nuevo patrón se añade a la clase $c_1 = \{x_1, x_3, x_5\}$ y se actualiza su centro $v_1 = \{208.33, 167.33, 127.67\}$.

6) sexto patrón $x_6 = \{92, 138, 54\}$ calculando las distancias a los tres centros de clase existentes $d(x_6, v_1) = 140.79$, $d(x_6, v_2) = 10.20$ y $d(x_6, v_3) = 128.74$ · siendo el mínimo $d(x_6, v_2) < T$ por tanto, el nuevo patrón se añade a la clase $c_2 = \{x_2, x_6\}$ y se actualiza su centro $v_2 = \{91, 134, 57\}$.

Tema 04 III : Aprendizaje

◆ Aprendizaje: cuantización vectorial

Ejercicio_09_10.m

7) séptimo patrón $x_7 = \{87, 128, 66\}$ calculando las distancias a los tres centros de clase existentes $d(x_7, v_1) = 141.67$, $d(x_7, v_2) = 11.53$ y $d(x_7, v_3) = 119.22$ siendo el mínimo $d(x_7, v_2) < T$, por tanto, el nuevo patrón se añade a la clase $c_2 = \{x_2, x_6, x_7\}$ y se actualiza su centro $v_2 = \{89.67, 132.00, 60.00\}$.

8) octavo patrón $x_8 = \{41, 22, 37\}$ calculando las distancias a los tres centros de clase existentes $d(x_8, v_1) = 239.46$, $d(x_8, v_2) = 122.46$ y $d(x_8, v_3) = 9.27$ siendo el mínimo $d(x_8, v_3) < T$, por tanto, el nuevo patrón se añade a la clase $c_3 = \{x_4, x_8\}$ cuyo centro se actualiza a $v_3 = \{38.0, 22.5, 40.5\}$.

Clasificación

Finalmente, calculamos las distancias del patrón A a cada uno de los centros dados $v_1 = \{208.33, 167.33, 127.67\}$, $v_2 = \{89.67, 132.00, 60.00\}$, $v_3 = \{38.0, 22.5, 40.5\}$, resultando: $d(A, v_1) = 137.36$; $d(A, v_2) = 15.97 < T$; $d(A, v_3) = 115.76$

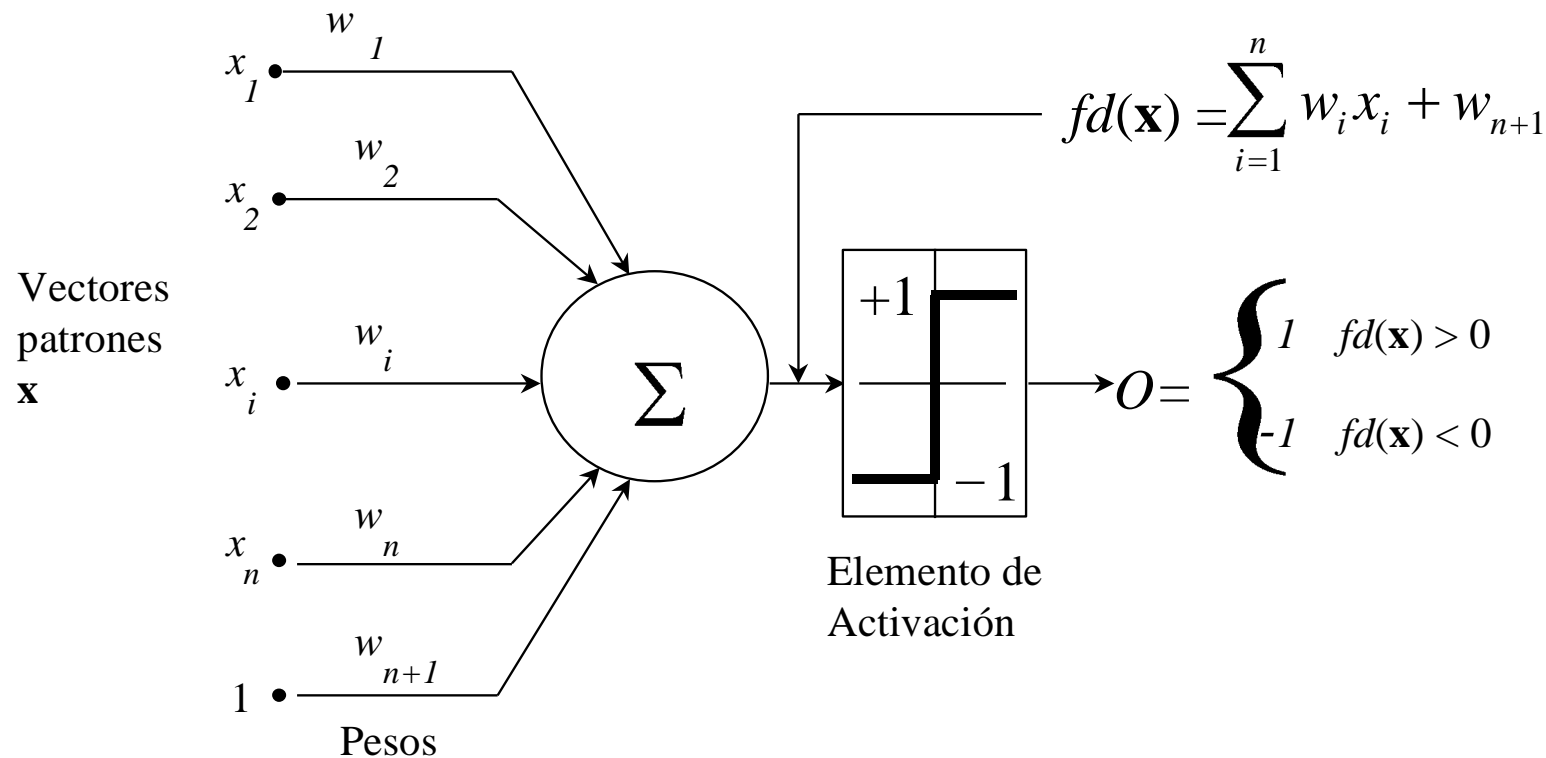
Resultando por tanto, que A pertenece a la clase c_2

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** modelos conexionistas, el perceptrón

Objetivo

Aprender una función discriminante: $fd(\mathbf{x}) = \sum_{i=1}^n w_i x_i + w_{n+1}$



Tema 04 III : Aprendizaje

◆ **Aprendizaje:** modelos conexionistas, el perceptrón


Algoritmo

- 1.- **Inicialización de los pesos y del umbral:** inicialmente se asignan valores aleatorios a cada uno de los pesos w_i $i = 1, 2, \dots, n$ y al umbral w_{n+1}
- 2.- **Presentación de un nuevo par (Entrada, Salida esperada):** presentar un nuevo patrón de entrada $\mathbf{x}_p = \{x_1, x_2, \dots, x_n\}$ junto con la salida esperada $fd_i(k)$
- 3.- **Cálculo de la salida actual:** $y(k) = f[\mathbf{w}^t \mathbf{x}_i + w_{n+1}]$, siendo en este caso f la función de transferencia escalón.
- 4.- **Adaptación de los pesos:** $w_i(k+1) = w_i(k) + \alpha(k)[fd_i(k) - y(k)]x_i$
La salida esperada $fd_i(k)$ es 1 si el patrón pertenece a la clase A y -1 si es de la clase B
- 5.- Si no hay convergencia (los pesos no cambian) **volver al paso 2**

Tema 04 III : Aprendizaje

◆ Aprendizaje: El perceptrón, ejemplo 1

Ejercicio: suponer el ejemplo biclase dado a continuación con $\alpha = 1/2$



Pesos iniciales: $w_1 = w_2 = w_3 = 0$

Vectores patrón aumentados:

$$c_1: \begin{aligned} x_1 &= (0,0,1)^t \\ x_2 &= (0,1,1)^t \end{aligned} \quad fd_i = 1$$

$$c_2: \begin{aligned} x_3 &= (1,0,1)^t \\ x_4 &= (1,1,1)^t \end{aligned} \quad fd_i = -1$$

Tema 04 III : Aprendizaje

◆ Aprendizaje: El perceptrón, ejemplo 1

1. Inicialización: $\mathbf{w}^t(1) = (0,0,0)$; $\alpha = 1/2$

2.1 Patrón $\mathbf{x} = \{0,0,1\}$: $\mathbf{w}^t \mathbf{x} = 0(0)+0(0)+0(1)=0$; $O = -1$, error = $(fd_i - O)=1+1=2$

Pesos modificados: $\mathbf{w}^t(2) = \mathbf{w}^t(1) + \mathbf{x} = (0,0,1)$

2.2 Patrón $\mathbf{x} = \{0,1,1\}$: $\mathbf{w}^t \mathbf{x} = 1$; $O = 1$, error = $(fd_i - O)=1 - 1 = 0 \Rightarrow$

Pesos **no** modificados: $\mathbf{w}^t(3) = \mathbf{w}^t(2)$

2.3 Patrón $\mathbf{x} = \{1,0,1\}$: $\mathbf{w}^t \mathbf{x} = 1$; $O = 1$, error = $(fd_i - O)=-1 - 1 = -2$

Pesos modificados: $\mathbf{w}^t(4) = \mathbf{w}^t(3) - \mathbf{x} = (-1,0,0)$

2.4 Patrón $\mathbf{x} = \{1,1,1\}$: $\mathbf{w}^t \mathbf{x} = -1$; $O = -1$, error = $(fd_i - O)=-1 + 1 = 0$

Pesos **no** modificados: $\mathbf{w}^t(5) = \mathbf{w}^t(4)$

Repetir otra serie de entrenamiento con los mismos patrones:

Llegando finalmente en la 10ª iteración a: $\mathbf{w}^t(10) = (-2,0,1)$, que corresponde al hallazgo de una función de decisión en el plano


$$fd_i = -2x_1 + 1$$

que es precisamente la recta $x_1 = 1/2$

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** El perceptrón, ejemplo 1

Función de decisión



Tema 04 III : Aprendizaje

◆ **Aprendizaje:** El perceptrón, ejemplo 2

Ejemplo: Ajuste de pesos para una red que realiza la función **OR** con $\alpha = 1$.

La salida esperada en cada caso es el resultado de la operación OR

1. Inicialización: $w_1 = 0.5$, $w_2 = 1.5$, $w_3 = 1.5$

2.1 Patrón $\mathbf{x} = \{0,0\}$: $\mathbf{w}^t \mathbf{x}_i = 0(0.5) + 0(1.5) + 1(1.5) = 1.5$; $O = 1$, error = $(fd_i - O) = 0 - 1 = -1$

Pesos modificados: $w_1 = 0.5 + (-1)0 = 0.5$; $w_2 = 1.5 + (-1)0 = 1.5$; $w_3 = 1.5 + (-1)1 = 0.5$

2.2 Patrón $\mathbf{x} = \{0,1\}$: $\mathbf{w}^t \mathbf{x}_i = 0(0.5) + 1(1.5) + 1(0.5) = 2$; $O = 1$, error = $(fd_i - O) = 1 - 1 = 0$

no se modifican los pesos. Tampoco se modifican para $\mathbf{x} = \{1,0\}$ y $\mathbf{x} = \{1,1\}$

3. Se toman de nuevo los cuatro patrones de entrada

3.1 Patrón $\mathbf{x} = \{0,0\}$: $\mathbf{w}^t \mathbf{x}_i = 0(0.5) + 0(1.5) + 1(0.5) = 0.5$; $O = 1$, error = $(fd_i - O) = 0 - 1 = -1$

Pesos modificados: $w_1 = 0.5 + (-1)0 = 0.5$; $w_2 = 1.5 + (-1)0 = 1.5$; $w_3 = 0.5 + (-1)1 = -0.5$

3.2 Patrón $\mathbf{x} = \{0,1\}$: $\mathbf{w}^t \mathbf{x}_i = 0(0.5) + 1(1.5) + 1(-0.5) = 1$; $O = 1$, error = $(fd_i - O) = 1 - 1 = 0$

no se modifican los pesos. Lo mismo para los patrones $\mathbf{x} = \{1,0\}$ y $\mathbf{x} = \{1,1\}$

4. Se toman de nuevo los cuatro patrones de entrada


4.1 Patrón $\mathbf{x} = \{0,0\}$: $\mathbf{w}^t \mathbf{x}_i = 0(0.5) + 0(1.5) + 1(-0.5) = -0.5$; $O = 0$, error = $(fd_i - O) = 0 - 0 = 0$

Ya no se modifican los pesos

Tema 04 III : Aprendizaje


◆ Aprendizaje: El perceptrón, ejemplo 2

Ejemplo: Ajuste de pesos para OR y problema para XOR



OR

Existe recta separando las clases



XOR

NO existe recta que separe las clases

Tema 04 III : Aprendizaje

◆ Aprendizaje: El perceptrón, multicapa

Ejemplo: solución para XOR

Pesos


$$w_{11} = w_{12} = w_{21} = w_{22} = w_{31} = 1; w_{32} = -1.5$$
$$\theta_1 = 0.5; \theta_2 = 1.5; \theta_3 = 0.5$$

Salidas de las neuronas

$$y_1 = f(w_{11}x_1 + w_{12}x_2 - \theta_1) = f(x_1 + x_2 - 0.5)$$

$$y_2 = f(w_{21}x_1 + w_{22}x_2 - \theta_2) = f(x_1 + x_2 - 1.5)$$

$$y_3 = f(w_{31}y_1 + w_{32}y_2 - \theta_3) = f(y_1 + y_2 - 0.5)$$



Resultados

x_1	x_2	y_1	y_2	$y_3 = \text{XOR}$
0	0	$f(-0.5) = 0$	$f(-1.5) = 0$	$f(-0.5) = 0$
0	1	$f(0.5) = 1$	$f(-0.5) = 0$	$f(0.5) = 1$
1	0	$f(0.5) = 1$	$f(-0.5) = 0$	$f(0.5) = 1$
1	1	$f(1.5) = 1$	$f(0.5) = 1$	$f(1.5) = 1$

Tema 04 III : Aprendizaje

◆ Aprendizaje: El perceptrón, ejercicio propuesto

Ejemplo: suponer el ejemplo biclase dado a continuación con $\alpha = 1/2$


Clases

○ c_1

○ c_2

Pesos iniciales: $w_1 = w_2 = w_3 = 0$

Vectores patrón aumentados:



$$\begin{aligned} c_1: \quad & x_1 = (0,1,1)^t \\ & x_2 = (0,2,1)^t \\ & x_3 = (1,2,1)^t \end{aligned} \quad fd_i = 1$$

$$\begin{aligned} c_2: \quad & x_4 = (1,0,1)^t \\ & x_5 = (2,0,1)^t \\ & x_2 = (2,1,1)^t \end{aligned} \quad fd_i = -1$$

Verificar que $\mathbf{w}^t = (-1, 1, 0)$, siendo la función de decisión: $fd_i = -x_1 + x_2$

Tema 04 III : Aprendizaje

◆ **Aprendizaje:** modelos conexionistas, el perceptrón

Regla Delta de Mínimos Cuadrados: clases no separables

El **objetivo** es ajustar los pesos para minimizar el error al cuadrado E_{tot} entre la salida deseada fd_i , con , que representa la decisión del maestro y la salida actual o real para el número de muestras de entrenamiento n .

$$E_{tot}(\mathbf{w}, \mathbf{X}) = \sum_{i=1}^n (\mathbf{w}^t \mathbf{x}_i - fd_i)^2$$

Actualización de los pesos de conexión:

$$\mathbf{w}(k+1) = \mathbf{w}(k) \pm \alpha \nabla_{\mathbf{w}} E_{tot}(\mathbf{w}, \mathbf{X}) \Big|_{\mathbf{w}(k)}$$



$$\nabla_{\mathbf{w}} E_{tot}(\mathbf{w}, \mathbf{X}) = 2 \sum_{i=1}^n (\mathbf{w}^t \mathbf{x}_i - fd_i) \mathbf{x}_i \quad \Longrightarrow \quad \mathbf{w}(k+1) = \mathbf{w}(k) \pm \alpha(k) \sum_{i=1}^n \frac{(\mathbf{w}^t \mathbf{x}_i - fd_i) \mathbf{x}_i}{\|\mathbf{x}_i\|}$$


$\alpha(k)$: razón de aprendizaje en $[0,1]$

◆ **Aprendizaje: red backpropagation**



Reconocimiento de caracteres

◆ Aprendizaje: Red retropropagación



Tema 5 : Aprendizaje

◆ **Aprendizaje:** Red retropropagación

Un ejemplo de aplicación:

Clasificación de texturas mediante imágenes multiespectrales

Clasificación de texturas mediante redes neuronales (CEDEX) Pajares y col.